

# IF69D-S11 Proc. Digital de Imagens

## APNP

### Aula 07

Universidade Tecnológica Federal do Paraná - UTFPR - Curitiba  
Departamento Acadêmico de Eletrônica - DAELN  
Curso de Engenharia Eletrônica  
Prof. Gustavo B. Borba

06.abr.2021



# Detecção de bordas

- Bordas são descontinuidades na intensidade dos níveis de cinza.


- Deseja-se que um processo de detecção de bordas apresente na saída uma imagem binária, que indica as bordas da imagem de entrada.

Edge detection

IN



OUT Canny



BINÁRIA

Octave:  
FUNÇÃO edge


& Berkeley

BW ← White (branco)  
black  
correspondem  
às BORDAS  
da imagem  
de entrada


# Detecção de bordas

Cammy


IN




OUT ↓



Textura IN



OUT




# Detecção de bordas por gradiente (primeira derivada)

existe tb: Fina + diff.

$$\frac{df}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x-h)}{2h} = \frac{f(x+1) - f(x-1)}{2}$$



central diff.

Imagem ↗



- A derivada de uma constante (não tem variação) é zero.
- A derivada de um degrau é um impulso.
- A derivada de uma reta (inclinação constante) é uma constante.

PERFIL



```
row = img(1,1:ncol);
% Derivada de
% primeira ordem
% segundo definição
for k=2:ncol-1
    d(k)=row(k+1)-row(k-1);
end
d=d/2; % Derivada 1a
```

Detecção de  
bordas por  
gradiente  
(primeira  
derivada)  
usando a  
convolução




$$c \cdot 1 + a \cdot (-1)$$

a	b	c
$\frac{1}{x}$	$\frac{1}{x}$	$\frac{1}{x}$
-1	0	1

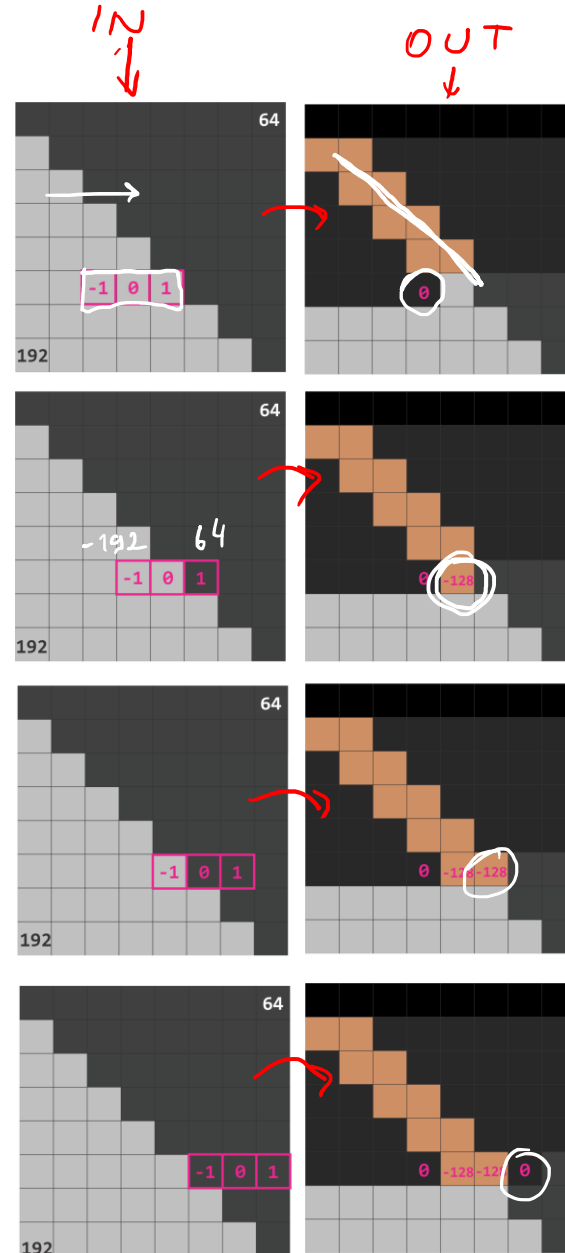

```
row = img(1,1:ncol);
% Derivada de
% primeira ordem
% segundo definição
for k=2:ncol-1
    d(k)=row(k+1)-row(k-1);
end
d=d/2; % Derivada 1a
```

```
% Máscara para derivada 1a
% por convolução para
% reproduzir f(x+1)-f(x-1).
% Fazer conv com [1 0 -1] e
% não com [-1 0 1] porque a
% convolução espelha a
% máscara em x e y.
h = [1 0 -1];
d = conv(row,h,'valid');
```

















Imagem








# Detecção de bordas por gradiente (primeira derivada) com a convolução nas duas direções (máscaras vertical e horizontal)



# Detecção de bordas por gradiente (primeira derivada) com a convolução nas duas direções (máscaras vertical e horizontal)



# Detecção de bordas por gradiente (primeira derivada) com a convolução nas duas direções (máscaras vertical e horizontal)





# Detecção de bordas por gradiente (primeira derivada)

Máscaras mas utilizadas:

de  
CONVOLUÇÃO

BORDA  
esc. cloro

-1	0	1
-1	0	1
-1	0	1

Prewitt vertical  
(para bordas verticais)

Respondem com mais intensidade às variações ao longo da direção horizontal.  
Variações ao longo da direção horizontal são bordas verticais.

-1	0	1
-2	0	2
-1	0	1

Sobel Vertical  
(para bordas verticais)

-1	-1	-1
0	0	0
1	1	1

Prewitt horizontal  
(para bordas horizontais)

Respondem com mais intensidade às variações ao longo da direção vertical.  
Variações ao longo da direção vertical são bordas horizontais.

-1	-2	-1
0	0	0
1	2	1

Sobel horizontal  
(para bordas horizontais)

$$\Sigma = 0$$

SOBEL


Detecção de bordas por gradiente (primeira derivada)  
 Combinando as saídas das máscaras nas duas direções:

Magnitude do gradiente:


$$M(i, j) = \sqrt{G_v(i, j)^2 + G_h(i, j)^2}$$

Módulo de um  
vetor

Magnitude do  
gradiente




A saída esperada de um detector de bordas é uma imagem binária. Para binarização automática utiliza-se alguma técnica adequada para a aplicação.



# Detecção de bordas por gradiente (primeira derivada)


Orientação (ângulo) do vetor magnitude do gradiente e da borda:

Imagem de entrada



$$\theta(i, j) = \underbrace{\tan^{-1}}_{\text{arctg}} \left( \frac{G_h(i, j)}{G_v(i, j)} \right)$$

NaN	NaN	NaN	NaN	NaN	NaN	45.00	71.57
NaN	NaN	NaN	NaN	NaN	45.00	45.00	63.43
NaN	NaN	NaN	NaN	45.00	45.00	45.00	45.00
NaN	NaN	NaN	45.00	45.00	45.00	45.00	NaN
NaN	NaN	45.00	45.00	45.00	45.00	NaN	NaN
NaN	45.00	45.00	45.00	45.00	NaN	NaN	NaN
45.00	45.00	45.00	45.00	NaN	NaN	NaN	NaN
18.43	26.57	45.00	NaN	NaN	NaN	NaN	NaN



1. A referência é o eixo vertical (0°)
2. O ângulo obtido para a magnitude do gradiente é  $\theta = 45^\circ$
3. A borda é ortogonal à magnitude do gradiente
4. O ângulo da borda é dado por  $\theta - 90^\circ = 45^\circ - 90^\circ = -45^\circ$

45


-45

Figura adaptada de Rafael C. Gonzalez, Richard E. Woods, Steven L. Eddins, Digital image processing, Pearson Prentice Hall, 3rd ed, 2008, Fig. 10.12.



# Detecção de bordas por derivada segunda

- A derivada de uma constante (não tem variação) é zero.
- A derivada de um degrau é um impulso.
- A derivada de uma reta (inclinação constante) é uma constante.


```
row = img(1,1:ncol);  
% Derivada de  
% primeira ordem  
for k=2:ncol-1  
    d(k)=row(k+1)-row(k-1);  
end  
d=d/2; % Derivada 1a  
  
% Derivada de  
% segunda ordem  
for k = 2 : ncol-1  
    dd(k)=d(k+1)-d(k-1);  
end  
dd=dd/2; % Derivada 2a
```




Detecção de bordas por derivada segunda. Operador que implementa derivada segunda de uma imagem: *Laplaciano*




**MUITO SENSÍVEL**  
Limiar baixo na detecção de  
passagem por zero



**MÉDIO**  
Limiar médio na detecção de  
passagem por zero



**POUCO SENSÍVEL  
A RUÍDO**  
Limiar alto na detecção de  
passagem por zero






Detecção de bordas por derivada segunda. *Laplaciano* (derivada segunda 'pura') é muito sensível ao ruído. Utiliza-se então a função **Laplaciano do Gaussiano (LoG)**, que combina a derivada segunda com uma suavização. O **LoG** pode ser entendido como um Gaussiano (passa-baixas) associado a um Laplaciano: realiza uma suavização e a derivada segunda.

```
% Gera um LoG de sigma=4 em uma janela 31x31
% É 31x31 pois o objetivo é apenas visualizar
% uma LoG e não convoluir com uma imagem
logf = fspecial('log', [31 31], 4);
p = logf(16,:); %linha central
```


```
%Display
figure
mesh(-logf, 'EdgeColor', 'black')
title('LoG sigma=4')
figure
plot(1:31,-p, 'LineWidth',2)
xlim([1 31])
grid
title('Perfil do LoG')
```



PARÂMETROS:



Sigma, tam. da janela LoG

na detec.  
de edge  
↓  
Limiar  
da zero-crossing




DOG  
difference  
of  
Gaussians

# Detecção de bordas por derivada segunda. Laplaciano do Gaussiano (LoG)




ZERO-CROSSING  
DETECTION


Limiar fixo para deteccão de  
passagem por zero. Sigma = 1



Limiar fixo para deteccão de  
passagem por zero. Sigma = 2



Limiar fixo para deteccão de  
passagem por zero. Sigma = 3






Detecção de bordas por **compass operator**.


Máscaras compass do método de **Kirsh**:

H, V



A saída do detector de bordas de Kirsh é o máximo das saídas das oito máscaras. A orientação é a da própria máscara que forneceu o máximo (múltiplos de  $45^\circ$ ).

Detecção de bordas por compass operator.  
Máscaras compass do método de *Kirsh*:



Na prática, o método de Kirsh fornece resultados bastante parecidos aos dos filtros de gradiente. Por isso, para aplicações em geral, o método de Sobel é mais indicado que os baseados em compass masks.

deriv. 1<sup>a</sup>

Detecção de bordas pelo método de **Canny**. É o mais utilizado. É basicamente um método para limiarizar a magnitude do gradiente. Há muitas variações da implementação. Uma possibilidade:


Low-Pass

1) LPF usando o Gaussiano.

2) Calcula magnitude do gradiente usando máscaras Sobel.



3) Nonmaximal supression: um pixel só é mantido (considerado borda e analisado no próximo passo) se tiver magnitude do gradiente maior que seus vizinhos determinados pela **direção** do seu gradiente.



"Faz edge detec. aí"  
↓  
"Beleê, vou passar um Canny"


4) Histeresys threshoding: limiares  $T_L$  e  $T_H$ . Se  $> T_H \rightarrow$  strong edge

Se entre  $T_L$  e  $T_H \rightarrow$  weak edge

5) Edge linking: incorpora pixels de weak edge dentro de uma vizinhança 8 de um strong pixel.

Detecção de bordas pelo método de **Canny**. É o mais utilizado.  
É basicamente um método para limiarizar a magnitude do gradiente.  
Há muitas variações da implementação

IN



OUT

